Южно-Уральский государственный университет

Курс «Основы интеллектуального анализа данных»

Лабораторная работа № 2

Классификация деревом решений (Census Income)

1. Формулировка задания

Разработать программу классификации с помощью дерева решений. Параметры: набор данных и критерий выбора атрибута разбиения (Information gain, Gain ratio, Gini index). Провести эксперименты на Census Income: сначала построить дерево на 100% обучающей выборки и визуализировать его. Затем добавить параметр доли обучающей выборки и метрики accuracy, precision, recall, F-мера; варьировать соотношение train:test от 60:40 до 90:10 с шагом 10%. Подготовить отчёт с рисунками и пояснениями.

2. Репозиторий с материалами

Исходные тексты, данные и результаты:

https://github.com/shibapc/1st-lab-int.analysis-of-data

3. Набор данных и метод

Census Income (Adult): признаки социально-демографического профиля (возраст, образование, семейное положение, занятость и др.), целевой класс — годовой доход ≤50K или >50K. Пропуски «?» удалены. Категориальные признаки кодируются порядковым кодированием; дерево строит бинарные разбиения «признак ≤ порог».

Критерии: Information gain — прирост информации по энтропии; Gain ratio — information gain, нормированный на split information (штраф за большое число ветвей); Gini index — уменьшение индекса Джини. Положительный класс для precision/recall/F1 — «>50K».

4. Метрики на 100% обучающей выборки (тест — adult.test)

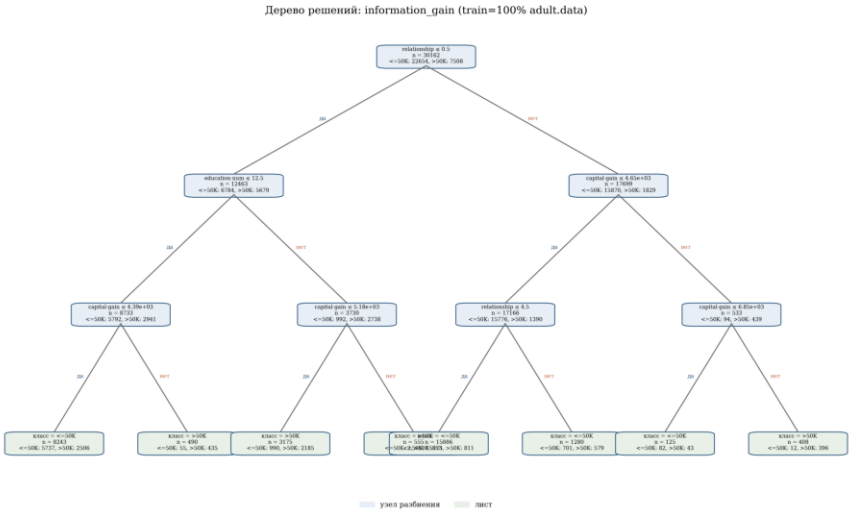
Критерий	Accuracy	Precision	Recall	F1	Глубина
information_gain	0.8497	0.7444	0.5911	0.6589	12
gain_ratio	0.8562	0.8013	0.5516	0.6534	12
gini_index	0.8485	0.7376	0.5949	0.6586	12

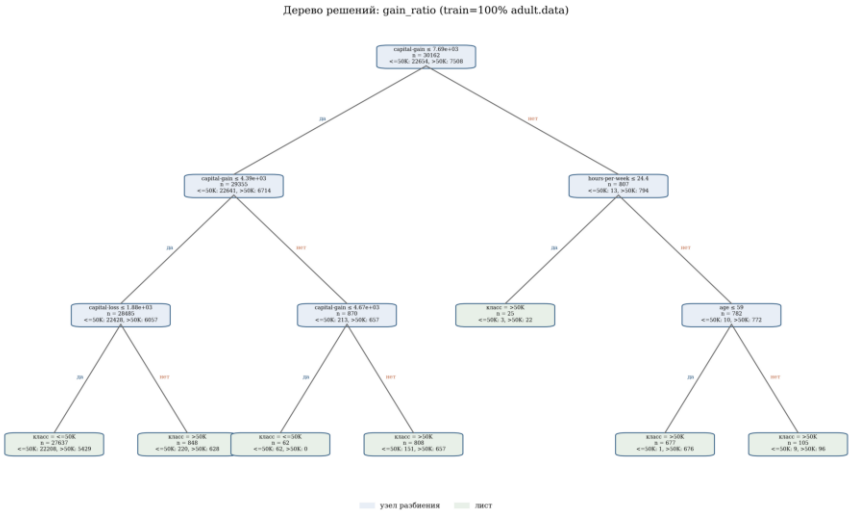
Южно-Уральский государственный университет

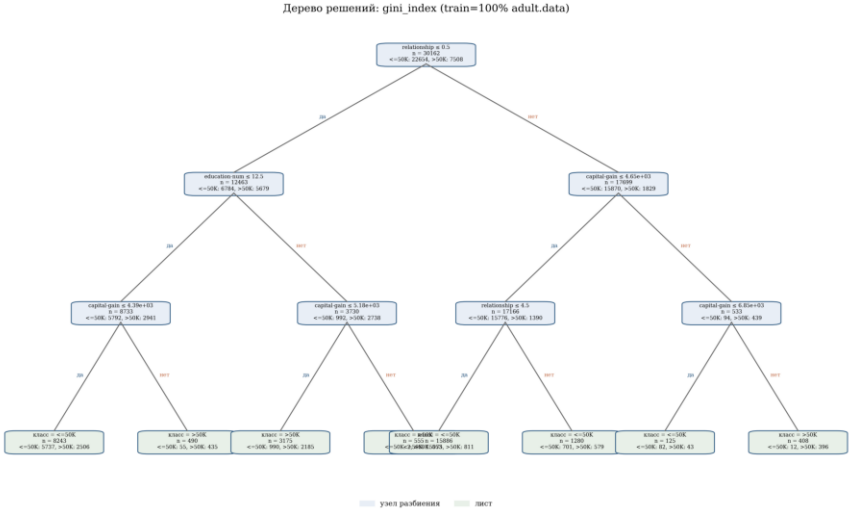
Курс «Основы интеллектуального анализа данных»

Визуализация деревьев решений

Рисунок 1–3. Деревья для трёх критериев (глубина отображения 3)







Южно-Уральский государственный университет

Курс «Основы интеллектуального анализа данных»

Показатели качества классификации

Рисунок 4. Метрики при фиксированном критерии gini_index

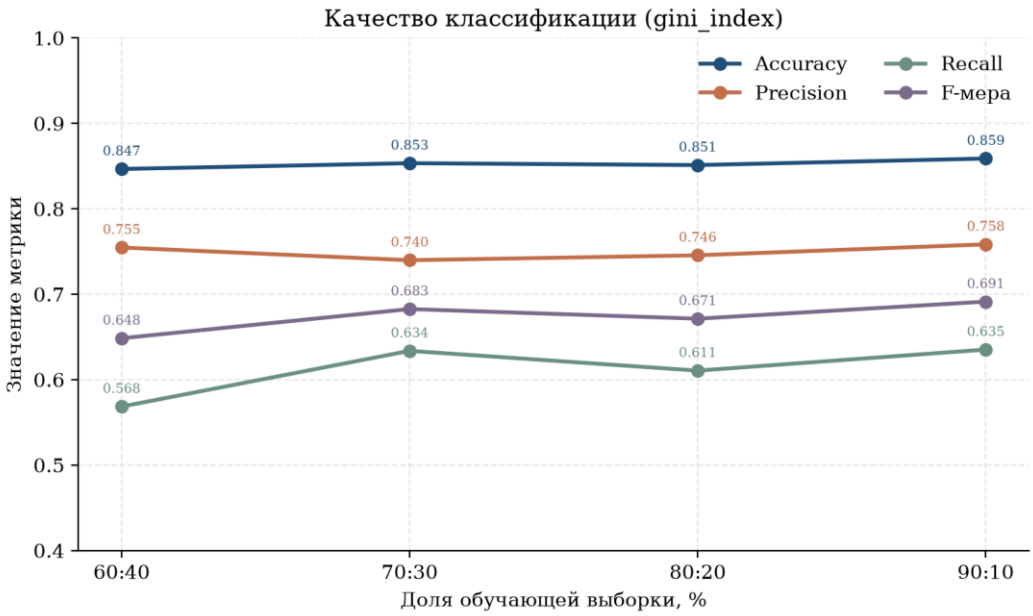
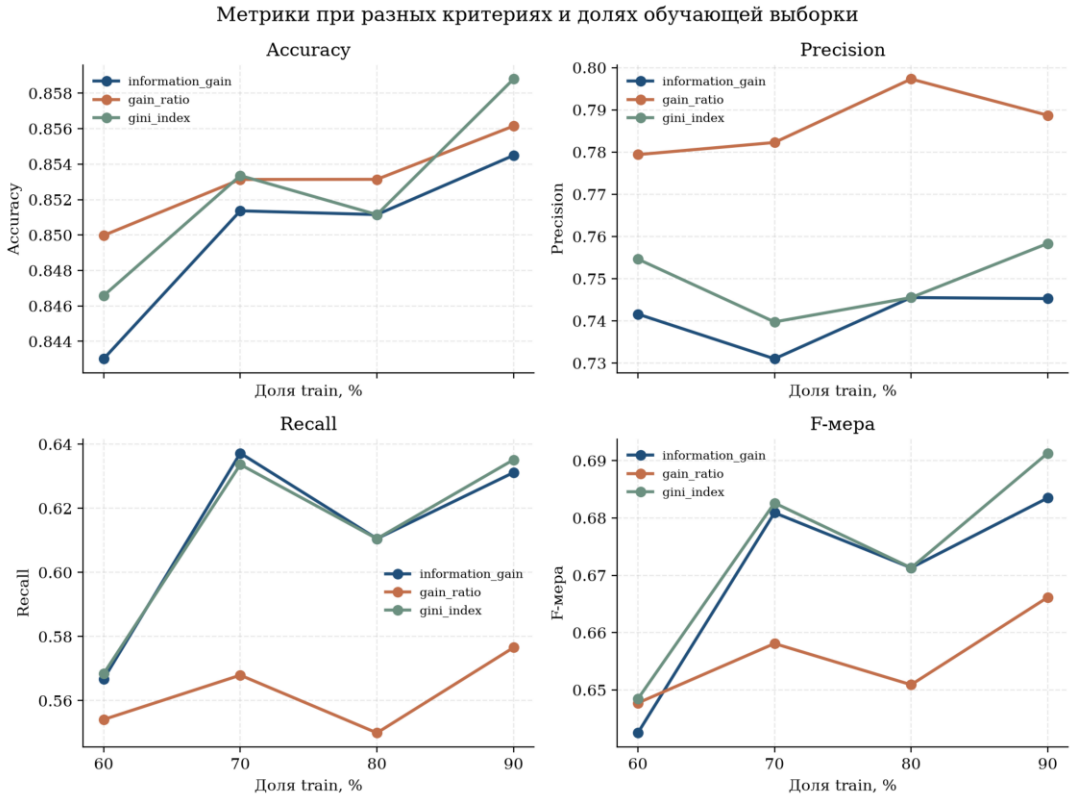


Рисунок 5. Сравнение всех критериев



Пояснение результатов

5. Смысл полученных результатов

На полной обучающей выборке adult.data (после очистки ~30162 объектов) и тесте adult.test все три критерия дают близкую аккуратность около 85.0%–84.8%. По F-мере лучше всего себя показал критерий information_gain (F1=0.659). Это согласуется с известными результатами для Adult: дерево решений уверенно отделяет доход >50K по образованию, семейному положению, capital-gain и часам работы.

Визуализация верхних уровней дерева показывает типичные разбиения: часто первыми идут capital-gain / marital-status / education-num — признаки, сильно связанные с доходом. Листья с доминирующим классом ≤50K соответствуют более частой доле населения с доходом ниже порога.

При фиксированном критерии gini_index и изменении доли обучения от 60% до 90%: 60:40 → acc=0.847, F1=0.648, 70:30 → acc=0.853, F1=0.683, 80:20 → acc=0.851, F1=0.671, 90:10 → acc=0.859, F1=0.691. Рост доли обучения обычно слегка повышает устойчивость оценок, но на Adult разница невелика: выборка большая, стратифицированное разбиение сохраняет баланс классов. Precision и recall для класса >50K ниже accuracy — класс дохода выше 50K реже (~24%), поэтому ошибка «пропустить богатого» заметнее в recall, а ложные срабатывания бьют по precision.

Сравнение критериев на одних и тех же долях train показывает, что Information gain и Gini дают очень похожие кривые; Gain ratio иногда строит более компактные деревья за счёт штрафа за «широкие» разбиения. Для практики на Adult любой из трёх критериев приемлем; выбор влияет больше на форму дерева, чем на итоговую аккуратность.

6. Сводка по долям train (критерий gini_index)

Train:Test	Accuracy	Precision	Recall	F1
60:40	0.8466	0.7546	0.5684	0.6484
70:30	0.8534	0.7398	0.6337	0.6826
80:20	0.8512	0.7455	0.6105	0.6713
90:10	0.8588	0.7583	0.6352	0.6913