Практическая работа 4. Классификация с помощью ансамбля

1. Формулировка задания

Разработайте программу, которая выполняет классификацию заданного набора данных с помощью ансамбля. Параметрами программы являются набор данных, техника построения ансамбля (бэггинг, случайный лес или бустинг), число участников ансамбля и параметры выбранной техники.

Проведите эксперименты на наборе Census Income из задания «Классификация с помощью дерева решений», варьируя число участников ансамбля от 50 до 100 с шагом 10.

Выполните визуализацию полученных результатов в виде диаграммы показателей качества классификации (аккуратность, точность, полнота, F-мера) в зависимости от числа участников ансамбля. Нанесите на диаграмму значения показателей качества, полученные для одиночного дерева решений.

Подготовьте отчет о выполнении задания и загрузите отчет в формате PDF в систему. Отчет должен представлять собой связный и структурированный документ со следующими разделами:

- формулировка задания;
- гиперссылка на каталог репозитория с исходными текстами, наборами данных и др. сопутствующими материалами;
- рисунки с результатами визуализации;
- пояснения, раскрывающие смысл полученных результатов.

2. Гиперссылка на репозиторий

Репозиторий с исходными текстами, набором данных и сопутствующими материалами (каталог lab4/): https://github.com/shibapc/1st-lab-int.analysis-of-data

3. Набор данных и метод

Census Income (Adult): признаки социально-демографического профиля (возраст, образование, семейное положение, занятость и др.), целевой класс – годовой доход ≤50K или >50K. Пропуски «?» удалены, категориальные признаки закодированы так же, как в практической работе 3. Обучающая выборка – вся очищенная adult.data (30162 объекта), тестовая – adult.test (15060 объектов). Положительный класс для precision/recall/F1 – «>50K».

Бэггинг обучает деревья CART (критерий Джини, глубина 12, не менее 20 объектов в листе) на бутстреп-выборках того же размера, используя все признаки; итоговый ответ – голосование большинства. Случайный лес устроен так же, но на каждом разбиении рассматривает только √d признаков (для 14 признаков – 3). Бустинг – градиентный: деревья глубины 3 с темпом обучения learning_rate = 0.1 строятся последовательно и исправляют ошибки предыдущих. Во всех трёх техниках варьируется только число участников: 50, 60, 70, 80, 90, 100; random_state = 42.

Пример запуска программы: python main.py -t boosting -n 100 (техника, число участников). Серия экспериментов и построение диаграммы выполняются скриптом experiments.py.

4. Сводка экспериментов

В таблице приведены показатели одиночного дерева решений из практической работы 3 и трёх ансамблей при 100 участниках; все модели проверены на одной и той же выборке adult.test.

Модель	N	Accuracy	Precision	Recall	F1
дерево, information gain	—	0.8497	0.7444	0.5911	0.6589
дерево, gain ratio	—	0.8562	0.8013	0.5516	0.6534
дерево, gini index	—	0.8485	0.7376	0.5949	0.6586
Бэггинг	100	0.8548	0.7594	0.5989	0.6697
Случайный лес	100	0.8558	0.7810	0.5743	0.6619
Бустинг	100	0.8633	0.7915	0.6022	0.6840

5. Показатели качества классификации

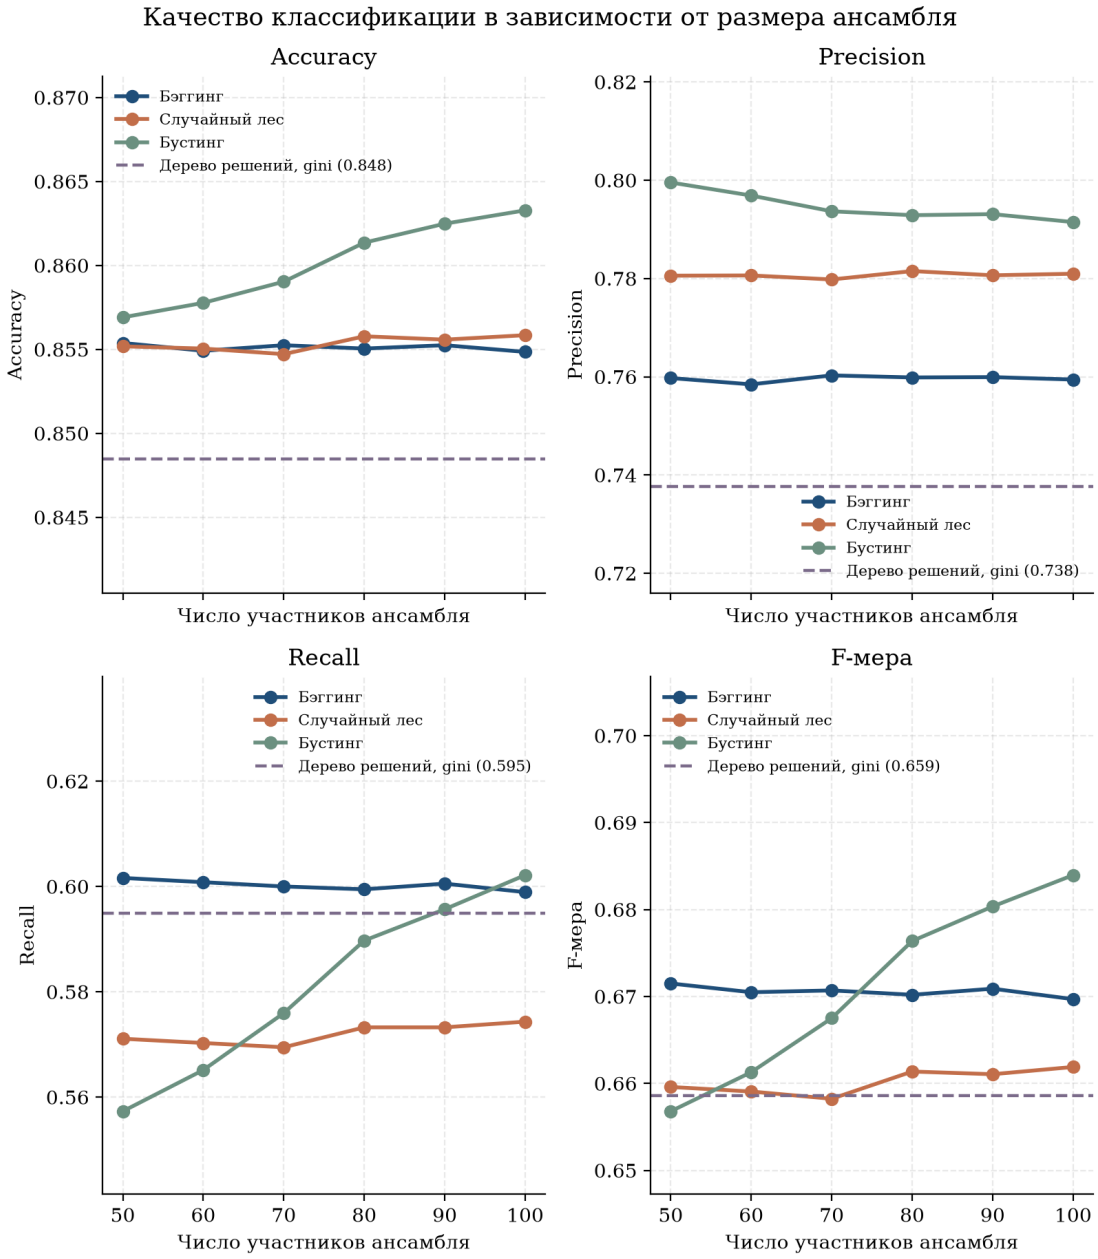


Рисунок 1 – Показатели качества классификации в зависимости от числа участников ансамбля (пунктир – одиночное дерево решений, критерий Gini)

6. Смысл полученных результатов

Доля класса >50K на тестовой выборке – 24.6 %. Из-за такого дисбаланса аккуратность легко держится около 85 %, даже если редкий класс найден не

полностью, поэтому на диаграмме помимо accuracy показаны precision, recall и F-мера для класса >50K.

Пунктир на каждой панели – одиночное дерево с критерием Gini из практической работы 3: accuracy = 0.848, precision = 0.738, recall = 0.595, F1 = 0.659. Именно этот критерий используют деревья бэггинга и случайного леса, а глубина (12) и минимальное число объектов в листе (20) совпадают с деревом из работы 3. Поэтому отрыв кривых от пунктира показывает эффект именно ансамблирования при той же сложности базового дерева.

Бэггинг и случайный лес уже к 50 участникам выходят на плато: дисперсия одиночного дерева к этому моменту усреднена, и увеличение ансамбля до 100 почти ничего не меняет. У бэггинга F-мера 0.671 → 0.670, полнота 0.602 → 0.599; у случайного леса F-мера 0.660 → 0.662, полнота 0.571 → 0.574. Бустинг в этом диапазоне продолжает обучаться: F-мера растёт с 0.657 до 0.684 (+0.027), полнота – с 0.557 до 0.602 (+0.045), аккуратность – с 0.857 до 0.863.

Случайный лес точнее бэггинга (precision 0.781 против 0.759), но хуже находит класс >50K (recall 0.574 против 0.599). Рассматривая на каждом разбиении лишь часть признаков, лес реже присваивает рискованную метку >50K, поэтому точность выше, а полнота и F-мера ниже, чем у бэггинга (F1 0.662 против 0.670).

Бустинг к 100 деревьям обгоняет обе техники и по аккуратности, и по F-мере (accuracy = 0.863, precision = 0.791, recall = 0.602, F1 = 0.684). Одно дерево глубины 3 заметно слабее дерева из работы 3, но цепочка из ста таких деревьев, каждое из которых исправляет ошибки предыдущих, строит более точную границу классов. При 50 участниках F-мера бустинга ещё ниже линии одиночного дерева, при 100 – отрыв уже устойчивый.

При 100 участниках прирост F-меры относительно дерева Gini составляет: бэггинг +0.011, случайный лес +0.003, бустинг +0.025. По аккуратности и точности все три ансамбля выше одиночного дерева: несколько деревьев

сглаживают разбиения, которые одно дерево подгоняет под обучающую выборку. По полноте выигрыш есть не у всех: случайный лес уступает дереву по recall и почти совпадает с ним по F-мере, то есть его преимущество – в более осторожных срабатываниях, а не в более полном обнаружении редкого класса.

Полные результаты для всех трёх техник и шести размеров ансамбля приведены в таблице ниже.

Модель	N	Accuracy	Precision	Recall	F1
Бэггинг	50	0.8554	0.7597	0.6016	0.6715
Бэггинг	60	0.8549	0.7584	0.6008	0.6705
Бэггинг	70	0.8552	0.7603	0.6000	0.6707
Бэггинг	80	0.8550	0.7598	0.5995	0.6702
Бэггинг	90	0.8552	0.7599	0.6005	0.6709
Бэггинг	100	0.8548	0.7594	0.5989	0.6697
Случайный лес	50	0.8552	0.7806	0.5711	0.6596
Случайный лес	60	0.8550	0.7806	0.5703	0.6591
Случайный лес	70	0.8547	0.7798	0.5695	0.6582
Случайный лес	80	0.8558	0.7815	0.5732	0.6614
Случайный лес	90	0.8556	0.7806	0.5732	0.6611
Случайный лес	100	0.8558	0.7810	0.5743	0.6619
Бустинг	50	0.8569	0.7995	0.5573	0.6568
Бустинг	60	0.8578	0.7969	0.5651	0.6613
Бустинг	70	0.8590	0.7937	0.5759	0.6675
Бустинг	80	0.8614	0.7929	0.5897	0.6764
Бустинг	90	0.8625	0.7931	0.5957	0.6804
Бустинг	100	0.8633	0.7915	0.6022	0.6840